Homelab Lenovo Tiny · fase 5 · v1.0

Host de IA dedicado: EPYC com 5 placas de vídeo

Implementação detalhada do computador que comanda o rack de GPU em perfil 2020: compra, montagem, BIOS, Proxmox, máquina virtual com as 5 placas, modelos de IA, rede, monitoramento, liga/desliga sob demanda e testes

João Victor Paixão Zolim · github.com/joaovpzdev
Outubro de 2026 · acompanha o desenho técnico "Rack de GPU 2020 + host EPYC" rev. B (2 folhas A3)

1. Visão geral

O nó 5 (M720q) só consegue comandar uma placa de vídeo pelo OCuLink. Para chegar a cinco, o rack de GPU ganha um **computador próprio no nível de baixo**: uma placa-mãe de servidor com processador AMD EPYC, que tem 128 pistas PCIe e liga as cinco placas em x16 completo, sem divisão de banda.

Peça	Papel
Host EPYC ("host-ia")	Sexto nó do cluster Proxmox; fica desligado quando não está em uso
VM "ia" (Ubuntu Server 24.04)	Recebe as 5 placas por passthrough e roda os serviços de IA em Docker
Placas G1 a G4	Um modelo grande dividido em quatro (vLLM, tensor parallel = 4)
Placa G5	Transcrição (Whisper), embeddings e modelos pequenos (Ollama)
Open WebUI	Interface de chat, documentos e usuários; acesso só pela VLAN 20 e Tailscale
Nó 1 (Grafana, Zabbix)	Painéis de GPU, temperatura e consumo; sensores do BMC por IPMI
Nó 2 (Node-RED)	Botão para ligar o host pelo IPMI e fluxos que usam a IA (triagem de alertas)

Por que 4 + 1 e não 5 juntas: para dividir um modelo entre placas (tensor parallel), o número de placas precisa dividir as cabeças de atenção do modelo, que quase sempre são potências de 2. Com 5 placas, o modelo principal usa 4 e a quinta fica livre para os serviços de apoio, que de outro jeito disputariam memória com o modelo.

2. Hardware escolhido

Parte	Escolha	Por quê / alternativa
Placa-mãe	ASRock Rack ROMED8-2T (ATX, 305 × 244 mm)	7 slots PCIe 4.0 x16, 8 slots de memória, 2 × M.2, 2 × 10 GbE, BMC com IPMI e porta própria. Alternativa: Supermicro H12SSL-i (menos slots x16).
Processador	AMD EPYC 7302P (16 núcleos, 155 W)	128 pistas PCIe e 8 canais de memória. O "P" é a versão de um soquete, mais barata. Para IA nas placas, mais núcleos não ajudam muito.
Memória	8 × 16 GB DDR4-3200 RDIMM ECC (128 GB)	Um pente por canal: os 8 canais preenchidos dão a banda máxima. Precisa ser RDIMM (registrada).
Cooler	Noctua NH-U9 TR4-SP3 (125 mm)	Cabe nos 180 mm do nível de baixo e sopra da frente para trás, como o resto do quadro.
Disco	NVMe 2 TB PCIe 4.0 no M.2	Proxmox, disco da VM e os modelos (um modelo de 70B em 4 bits ocupa ~40 GB).
Fonte	ATX 3.1 1600 W 80+ Platinum	Precisa de saídas PCIe suficientes para todas as placas, sem adaptadores. ATX 3.1 aguenta melhor os picos rápidos das placas de vídeo.
Risers	5 × PCIe 4.0 x16 blindados, 30 cm	Ligam cada slot à sua baia, atravessando a chapa do meio pelo rasgo.
Placas de vídeo	5 × RTX 3060 12 GB (60 GB no total)	CUDA funciona direto. Upgrade natural: RTX 3090 24 GB (120 GB no total).

3. Antes de comprar

- **Processador sem trava de fabricante.** Dell e Lenovo usam o AMD Platform Secure Boot (PSB) para prender o EPYC às placas deles. Um processador usado que veio desses servidores pode não funcionar na ROMED8-2T. Compre anúncios que digam *unlocked*, *sem PSB* ou *tray*, e peça foto da etiqueta sem marca de fabricante.

- **Versão da BIOS.** A ROMED8-2T aceita EPYC 7002 e 7003; para os 7003, a placa pode precisar de BIOS mais nova. Com o 7302P (7002) ela liga em qualquer versão, e a BIOS pode ser atualizada depois pela interface do BMC.
- **Memória RDIMM.** Pente comum (UDIMM) de computador de mesa não funciona. Os 8 pentes iguais, mesma marca e velocidade.
- **Fonte.** Conte os conectores: RTX 3060 usa 1 × 8 pinos (alguns modelos 2); RTX 3090 usa 2 ou 3. A placa-mãe precisa do 24 pinos, de um EPS 8 pinos e de um 4 pinos.
- **Risers.** Prefira PCIe 4.0 blindado, todos do mesmo comprimento. Riser USB de mineração não serve.
- **Importação.** Placa-mãe de servidor quase sempre vem de fora: conte imposto, prazo e a falta de garantia; teste tudo assim que chegar.
- **Elétrica.** Com 5 placas, o rack vai a ~950 W (3060) ou ~1.300 W (3090). Peça a um eletricista uma tomada de 20 A exclusiva, com DPS, antes de passar de três placas.

4. Montagem física

Monte primeiro na bancada, com uma placa de vídeo só, e passe para o quadro depois que tudo funcionar.

1. **Bancada:** placa-mãe sobre a caixa dela (nunca sobre o saco antiestático), pulseira antiestática.
2. **Processador:** soltar os 3 parafusos Torx T20 da tampa do soquete na ordem 3-2-1, deslizar o processador (no suporte laranja) no trilho, fechar e apertar na ordem 1-2-3 com chave de torque (~1,8 N·m; confira no manual). O soquete SP3 tem milhares de pinos: não toque nem deixe cair nada nele.
3. **Cooler:** pasta térmica (o Noctua vem com a dele), suporte SP3 e ventoinha soprando para a borda de I/O.
4. **Memória:** os 8 pentes, um em cada slot.
5. **NVMe** no M.2 e **uma placa de vídeo** direto no slot 1, sem riser.
6. **Fonte:** 24 pinos, EPS 8 pinos, 4 pinos e o cabo da placa de vídeo.
7. **Rede:** porta do BMC (IPMI) e uma porta 10 GbE no switch, ambas na VLAN 20.
8. Ligar e acessar o BMC (seção 5). O primeiro boot de um servidor EPYC demora: 1 a 3 minutos de tela preta é normal.
9. **Quadro:** chapa de baixo com os espaçadores ATX, placa-mãe deitada com a borda de I/O para trás, fonte na frente à direita, ventoinhas de entrada na frente.
10. **Risers e baias:** uma placa por vez, de G1 a G5. Cada riser sai de um slot x16, sobe pelo rasgo da chapa e encaixa na baia; o suporte traseiro da placa é parafusado na barra 2020. Anote qual slot vai para qual baia.
11. **Cabos de energia** das placas sem dobras forçadas; abraçadeiras nos perfis, longe das ventoinhas.
12. **Aterramento:** um cabo do quadro ao parafuso da fonte.

5. Primeiro boot: BMC e BIOS

O BMC é um computador pequeno dentro da placa-mãe, ligado à porta IPMI. Ele dá tela remota, liga e desliga o host e lê os sensores, mesmo com o host desligado.

1. Descubra o IP do BMC no DHCP do roteador ou no Pi-hole; abra no navegador.
2. Entre com a senha da etiqueta da placa (firmwares antigos usam admin/admin) e **troque a senha na hora**. Crie um usuário próprio, por exemplo *ia-admin*.
3. Atualize o firmware do BMC e depois a BIOS, pelo próprio BMC.
4. Fixe o IP do BMC (ex.: 10.0.20.60) e o do host (ex.: 10.0.20.61) no DHCP.

Ajustes da BIOS:

Opção	Valor	Para quê
IOMMU (AMD CBS › NBIO)	Enabled	Passar as placas de vídeo para a VM
Above 4G Decoding	Enabled	Endereçar a memória de 5 placas
Re-Size BAR	Disabled	Evita problemas no passthrough
ACS	Enabled	Cada placa no seu grupo IOMMU
CSM	Disabled (só UEFI)	Boot moderno e OVMF na VM
Velocidade dos slots PCIe	Auto; Gen3 se aparecer erro	Risers longos às vezes não aguentam Gen4
Restore on AC Power Loss	Power Off	Não ligar sozinho quando a luz volta

> **Ventoinhas silenciosas e BMC:** o BMC espera ventoinhas de servidor e pode achar que uma Noctua girando devagar está parada, acelerando tudo em ciclos. Se isso acontecer, baixe o limite mínimo de rotação com o ipmitool (comando abaixo, conferindo o nome do sensor).

```
ipmitool -I lanplus -H 10.0.20.60 -U ia-admin -f /root/.ipmi_senha sensor list | grep -i fan
ipmitool -I lanplus -H 10.0.20.60 -U ia-admin -f /root/.ipmi_senha sensor thresh FAN1 lower 100 200 300
```

6. Proxmox no host

1. Instale o Proxmox VE no NVMe pela tela remota do BMC (mídia virtual). Hostname *host-ia*, IP 10.0.20.61, bridge *vmbr0* com VLAN aware ligado.
2. Entre no cluster existente: *Datacenter › Cluster › Join*. O cluster passa a ter 6 nós; com o host-ia desligado ficam 5 de 6, e o quórum (4) continua garantido. Não coloque o host-ia em grupos de HA.
3. Ative o passthrough: carregue os módulos VFIO, prenda as placas NVIDIA ao vfio-pci e impeça o host de carregar drivers de vídeo nelas.

Os IDs mudam com o modelo da placa: se misturar 3060 e 3090, coloque os IDs das duas na linha do vfio.

```
# IDs das placas (vídeo e áudio de cada GPU)
lspci -nn | grep -i nvidia          # ex.: 10de:2504 (vídeo) e 10de:228e (áudio)

# linha de comando do kernel: acrescente iommu=pt
#   GRUB: GRUB_CMDLINE_LINUX_DEFAULT em /etc/default/grub  -> update-grub
#   ZFS/systemd-boot: /etc/kernel/cmdline                  -> proxmox-boot-tool refresh

cat >> /etc/modules <<'EOF'
vfio
vfio_iommu_type1
vfio_pci
EOF
echo "options vfio-pci ids=10de:2504,10de:228e disable_vga=1" > /etc/modprobe.d/vfio.conf
printf "blacklist nouveau\nblacklist nvidia\n" > /etc/modprobe.d/blacklist-gpu.conf
update-initramfs -u -k all && reboot

# depois do reboot: cada placa no seu grupo e presa ao vfio-pci
find /sys/kernel/iommu_groups/ -type l | sort -V | grep -i ":00.0"
lspci -nnk | grep -A3 -i nvidia     # "Kernel driver in use: vfio-pci"
```

7. VM "ia" com as 5 placas

Configuração	Valor
Sistema	Ubuntu Server 24.04 LTS
Máquina / firmware	q35 / OVMF (UEFI), sem Secure Boot
CPU	tipo host, 24 vCPUs (sobram 8 threads para o Proxmox)
Memória	96 GB fixos (balloon desligado: obrigatório com passthrough)
Disco	400 GB no NVMe (VirtIO SCSI single, iothread)
Rede	virtio na vmbr0, tag 20
PCI	5 placas inteiras (todas as funções), PCI-Express ligado

```
qm create 200 --name ia --machine q35 --bios ovmf --cpu host --cores 24 \
  --memory 98304 --balloon 0 --scsihw virtio-scsi-single \
  --net0 virtio,bridge=vmbr0,tag=20 --ostype l26 \
  --efidisk0 local-lvm:1,efitype=4m,pre-enrolled-keys=0 \
  --scsi0 local-lvm:400,iothread=1

# endereços de exemplo: use os do seu "lspci | grep -i nvidia"
qm set 200 --hostpci0 0000:01:00,pcie=1
qm set 200 --hostpci1 0000:21:00,pcie=1
qm set 200 --hostpci2 0000:41:00,pcie=1
qm set 200 --hostpci3 0000:61:00,pcie=1
qm set 200 --hostpci4 0000:81:00,pcie=1
```

> **Se a VM não enxergar todas as placas:** o OVMF reserva pouco espaço de memória PCI. Aumente com `qm set 200 --args "-fw_cfg name=opt/ovmf/X-PciMmio64Mb,string=65536"` e reinicie a VM.

8. Software de IA na VM

Driver, toolkit de contêiner e limite de potência

```
sudo apt update && sudo apt full-upgrade -y
sudo ubuntu-drivers install            # driver NVIDIA recomendado
sudo reboot
nvidia-smi                             # precisa listar as 5 placas

# Docker + NVIDIA Container Toolkit (repositório oficial da NVIDIA, ver documentação)
sudo apt install -y docker.io docker-compose-v2 nvidia-container-toolkit
sudo nvidia-ctk runtime configure --runtime=docker && sudo systemctl restart docker

# limite de potência em todo boot: /etc/systemd/system/gpu-limite.service
[Unit]
Description=Limite de potência das placas
After=multi-user.target
[Service]
Type=oneshot
ExecStart=/usr/bin/nvidia-smi -pm 1
ExecStart=/usr/bin/nvidia-smi -pl 150     # 3060; use 220 para 3090
[Install]
WantedBy=multi-user.target
```

Serviços (docker-compose.yml em /srv/ia)

```
services:
  vllm:                                  # modelo principal nas placas 0-3
    image: vllm/vllm-openai:latest
    ipc: host
    command: >
      --model Qwen/Qwen2.5-32B-Instruct-AWQ
      --tensor-parallel-size 4 --gpu-memory-utilization 0.90
      --max-model-len 16384 --api-key ${VLLM_KEY}
    volumes: ["/srv/modelos:/root/.cache/huggingface"]
    deploy:
      resources:
        reservations:
          devices: [{driver: nvidia, device_ids: ["0","1","2","3"], capabilities: [gpu]}]
    restart: unless-stopped

  ollama:                                # embeddings e modelos pequenos na placa 4
    image: ollama/ollama:latest
    volumes: ["/srv/ollama:/root/.ollama"]
    deploy:
      resources:
        reservations:
          devices: [{driver: nvidia, device_ids: ["4"], capabilities: [gpu]}]
    restart: unless-stopped

  whisper:                               # transcrição na placa 4
    image: onerahmet/openai-whisper-asr-webservice:latest-gpu
    environment: [ASR_ENGINE=faster_whisper, ASR_MODEL=medium]
    deploy:
      resources:
        reservations:
          devices: [{driver: nvidia, device_ids: ["4"], capabilities: [gpu]}]
    restart: unless-stopped

  open-webui:
    image: ghcr.io/open-webui/open-webui:main
    ports: ["3000:8080"]
    environment:
      - OPENAI_API_BASE_URL=http://vllm:8000/v1
      - OPENAI_API_KEY=${VLLM_KEY}
      - OLLAMA_BASE_URL=http://ollama:11434
    volumes: ["/srv/open-webui:/app/backend/data"]
    restart: unless-stopped
```

- O modelo do exemplo (32B em 4 bits, ~19 GB) cabe com folga nos 48 GB das quatro placas e deixa espaço para contexto longo. Um 70B em 4 bits (~40 GB) também cabe, com contexto curto. Troque pelo modelo da vez.
- Se o vLLM travar ao iniciar dentro da VM, teste a variável *NCCL_P2P_DISABLE=1*: placas de consumo atrás de risers nem sempre conversam direto entre si.
- Depois de criar a conta de administrador no Open WebUI, desligue novos cadastros (*ENABLE_SIGNUP=false*).
- Imagens e variáveis mudam entre versões: confira o README de cada projeto antes de atualizar.

9. Rede e segurança

Item	Regra
VLAN	Host, BMC e VM na VLAN 20 (lab). A VLAN 30 (alvos) não tem rota até eles.
BMC	Nunca exposto. Senha própria, firmware atualizado, acesso só da VLAN 20.
Rede 10 GbE	O TL-SG108E é 1 GbE: a porta negocia 1 Gb/s, suficiente para baixar modelos. A segunda porta 10 GbE fica para um switch 10 GbE no futuro.
Acesso de fora	Tailscale só na VM. Nenhuma porta aberta no roteador.
APIs	vLLM com chave (--api-key); Ollama sem porta publicada, só na rede interna do compose.
Dados	Alertas, logs e documentos ficam em casa. Nada é enviado para serviços de IA externos (LGPD).
Backup	Configuração da VM e volume do Open WebUI copiados para o SSD do nó 2. Modelos não precisam de backup: baixam de novo.

10. Monitoramento

- **Zabbix (nó 1):** host novo com interface IPMI apontando para o BMC: temperatura do processador, ventoinhas, tensões e consumo, mesmo com o host desligado.
- **Telegraf na VM** com o plugin *nvidia_smi*, enviando para o InfluxDB do nó 1: uso, memória, temperatura e potência de cada placa.
- **Grafana:** painel "IA" com as 5 placas lado a lado e o consumo total.
- **Alertas:** placa acima de 83 °C, erros PCIe (AER) no log, uma placa sumindo do nvidia-smi.

```
# /etc/telegraf/telegraf.d/gpu.conf (na VM)
[[inputs.nvidia_smi]]
  bin_path = "/usr/bin/nvidia-smi"
  timeout = "5s"

# conferir link PCIe de cada placa (geração e largura)
nvidia-smi -q -d PCIE | grep -E "Bus Id|Current"
sudo dmesg | grep -iE "aer|pcie bus error"
```

11. Liga/desliga sob demanda e energia

Ligado e parado, o host gasta cerca de 140 W: ~R$ 100 por mês só para esperar. A ideia é deixá-lo desligado e ligar quando for usar. O BMC continua acordado (~5 W) e liga o host pela rede.

Estado	5 × 3060 @150 W	5 × 3090 @220 W
Desligado (só o BMC)	~5 W	~5 W
Ligado, ocioso	~140 W	~170 W
Gerando texto com todas	~950 W	~1.300 W
Mês 24/7 (ocioso)	~R$ 100	~R$ 125
Mês sob demanda (~4 h/dia)	~R$ 50	~R$ 65

Tarifa considerada: ~R$ 1,00/kWh. Valores estimados.

Ligar (botão no Node-RED do nó 2 ou terminal do nó 1)

```
ipmitool -I lanplus -H 10.0.20.60 -U ia-admin -f /root/.ipmi_senha chassis power on
ipmitool -I lanplus -H 10.0.20.60 -U ia-admin -f /root/.ipmi_senha chassis power status
```

Desligar sozinho após 60 minutos parado (na VM, pelo cron a cada 5 min)

```
#!/bin/bash
# /usr/local/bin/ia-ocioso.sh
LIMITE=60
ARQ=/var/lib/ia-ultimo-uso
USO=$(nvidia-smi --query-gpu=utilization.gpu --format=csv,noheader,nounits | awk '{s+=$1} END {print s}')
if [ "$USO" -gt 5 ] || [ ! -f "$ARQ" ]; then date +%s > "$ARQ"; exit 0; fi
PARADO=$(( ( $(date +%s) - $(cat "$ARQ") ) / 60 ))
if [ "$PARADO" -ge "$LIMITE" ]; then
  ssh -i /root/.ssh/desligar root@10.0.20.61     # chave que só pode rodar "poweroff"
fi
```

No host, a chave pública vai em `/root/.ssh/authorized_keys` com `command="/sbin/poweroff",no-port-forwarding,no-pty` na frente: ela só sabe desligar. O Proxmox desliga a VM com segurança antes de apagar o host.

12. Testes de aceitação

Teste	Como	Passa se
Memória	MemTest86 pela mídia virtual do BMC, 1 passada completa	Zero erros
Grupos IOMMU	Comando da seção 6	Cada placa no seu grupo
Link PCIe	nvidia-smi -q -d PCIE	x16 em todas; Gen4 (ou Gen3 fixado)
Estresse das placas	gpu-burn por 30 min com o limite de potência	Sem erro, abaixo de 83 °C
Risers	dmesg durante o gpu-burn	Nenhum erro AER
Fonte	As 5 placas no máximo ao mesmo tempo	Não desarma
Modelo	vLLM com tensor parallel 4, 30 min de perguntas	Sem travar
Liga/desliga	Desligar pelo script e ligar pelo IPMI	Volta com a VM e os serviços
Disjuntor	Tudo no máximo por 1 h	Não desarma; tomada fria

13. Problemas comuns

Sintoma	Causa provável	Solução
Não liga, sem vídeo nem BMC	Processador travado (PSB) ou BIOS antiga	Testar outro processador; atualizar a BIOS pelo BMC
Placa some do nvidia-smi	Riser ou cabo de energia	Fixar o slot em Gen3; trocar o riser
Erros AER no log	Sinal ruim no riser	Riser mais curto e blindado; Gen3
Host desliga no pico	Picos rápidos das placas	Limite de potência; fonte ATX 3.1
Ventoinhas acelerando em ciclos	Limite do BMC para rotação baixa	Ajustar limites (seção 5)
VM não vê as 5 placas	Pouco espaço PCI no OVMF	Opção X-PciMmio64Mb (seção 7)
vLLM trava na inicialização	Comunicação direta entre placas	NCCL_P2P_DISABLE=1
Disjuntor desarma	Circuito comum	Tomada 20 A exclusiva com eletricista

14. Custos e caminho de compra

Item	R$ (estim.)
ASRock Rack ROMED8-2T (usada ou importada)	~3.500
AMD EPYC 7302P usado sem trava de fabricante	~900
8 × 16 GB DDR4-3200 RDIMM ECC	~1.300
Cooler Noctua NH-U9 TR4-SP3	~700
NVMe 2 TB PCIe 4.0	~900
Fonte ATX 3.1 1600 W Platinum	~2.600
5 risers PCIe 4.0 x16 blindados, 30 cm	~900
Quadro 2020 rev. B, chapas e ventoinhas	~1.500
Tomada 20 A exclusiva com DPS (eletricista)	~400
Host + quadro, sem placas de vídeo	**~12.700**
5 × RTX 3060 12 GB usadas	~7.000
Total com 5 × 3060	**~19.700**
Alternativa: 5 × RTX 3090 24 GB usadas	~25.000

1. **Agora:** quadro + uma RTX 3060 ligada ao nó 5 por OCuLink (fase 5). Já dá para usar.
2. **Host:** placa-mãe, processador, memória, cooler, NVMe e fonte. A placa de vídeo do nó 5 muda para a baia G1 e o nó 5 volta a ser um nó comum.
3. **Crescer:** uma placa por vez, de G2 a G5. Com 4 placas o vLLM já roda em tensor parallel.
4. **Depois:** trocar 3060 por 3090 aos poucos. Com placas misturadas, o vLLM fica limitado pela menor; agrupe placas iguais em G1–G4.

Preços estimados em outubro de 2026; usados e importados variam muito.