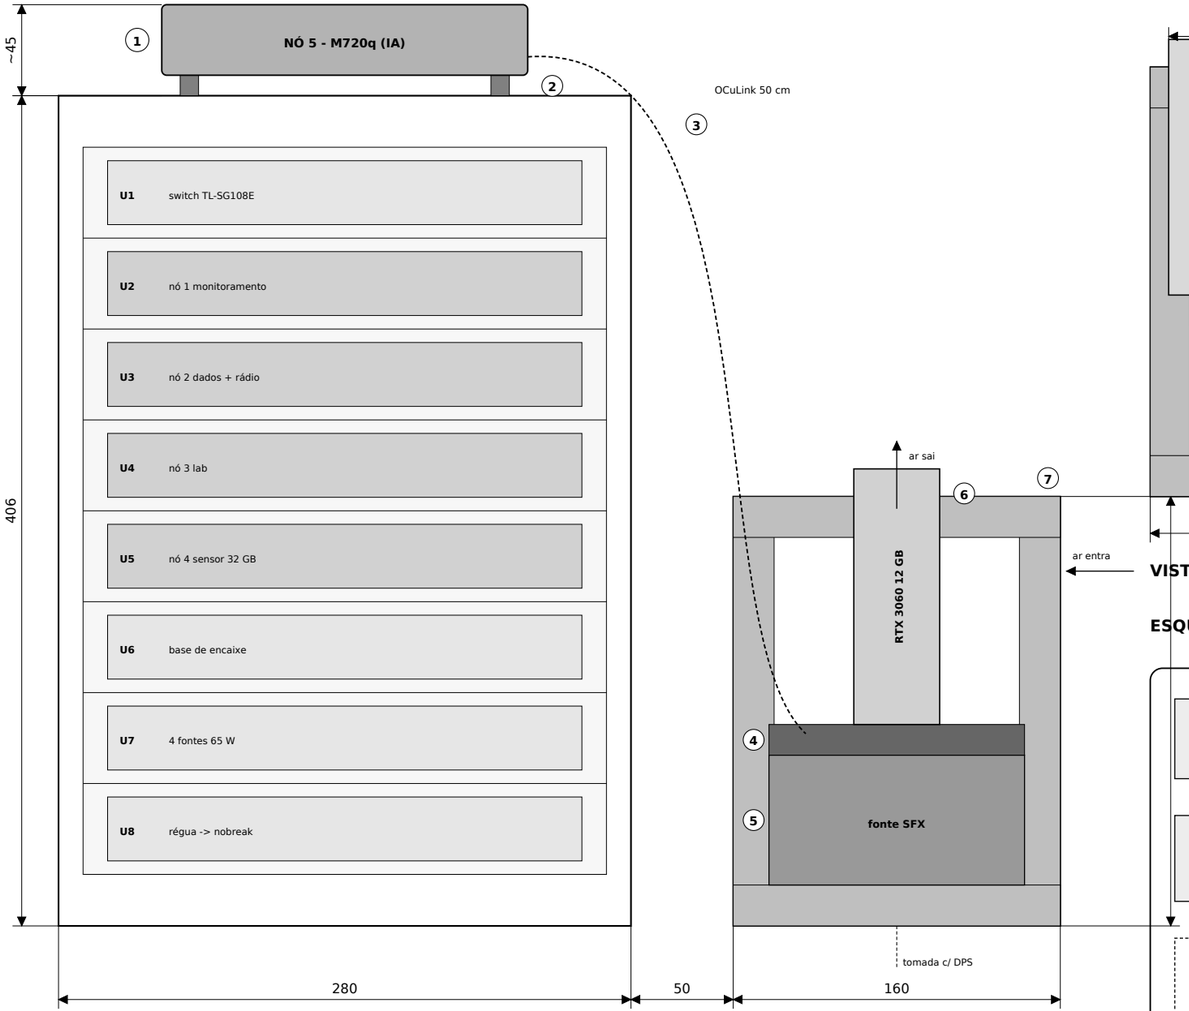
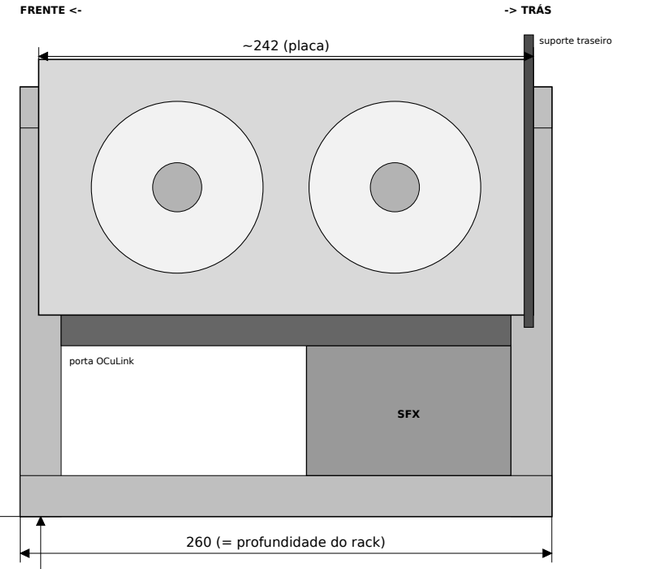


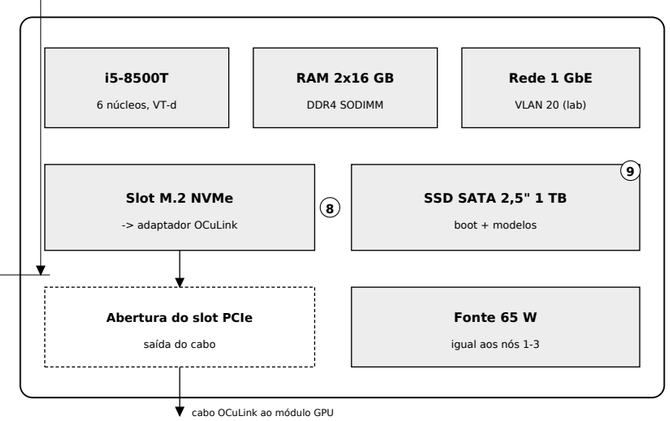
VISTA FRONTAL (1:3)

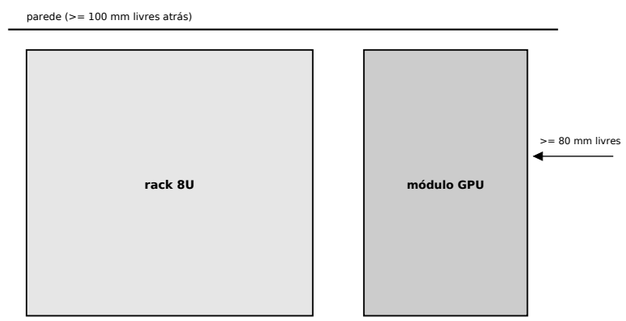
rack 8U sem alteração; nó 5 sobre pés impressos no tampo



VISTA LATERAL DIREITA DO MÓDULO (1:3)

ESQUEMA DO NÓ 5 (sem escala)





PLANTA (1:6) - frente para baixo

NOTAS

1. Nó 5 igual aos outros: mesma fonte, peças de reposição e cluster.
2. O M.2 NVMe vira OCuLink (PCIe 3.0 x4); o boot vai para o SSD SATA.
3. Para IA a banda x4 basta: o modelo carrega uma vez e roda na placa.
4. Ligue a GPU ANTES do nó 5.
5. Módulo fora do nobreak (DPS).
6. Medidas da placa variam por marca.

ITENS (balões)

N	Item	Medidas ~ (mm)
1	Lenovo M720q i5-8500T - nó 5	179 x 183 x 34,5
2	4 pés impressos + trava no tampo	ASA
3	Adaptador M.2 -> OCuLink + cabo	50 cm
4	Dock eGPU OCuLink (PCIe x16 aberto)	~130 x 100
5	Fonte SFX 600 W 80+ Gold	125 x 100 x 63,5
6	RTX 3060 12 GB (usada)	~242 x 125 x 42
7	Quadro em perfil de alumínio 2020	160 x 260 x 210
8	SSD SATA 2,5" 1 TB	100 x 70 x 7
9	2 x 16 GB DDR4 SODIMM	-

ALTERNATIVA DENTRO DO NÓ

Placa low profile no riser PCIe do M720q (ex.: RTX A1000 8 GB, 50 W): sem módulo externo, mas só 8 GB e fonte de 135 W. Conferir antes.

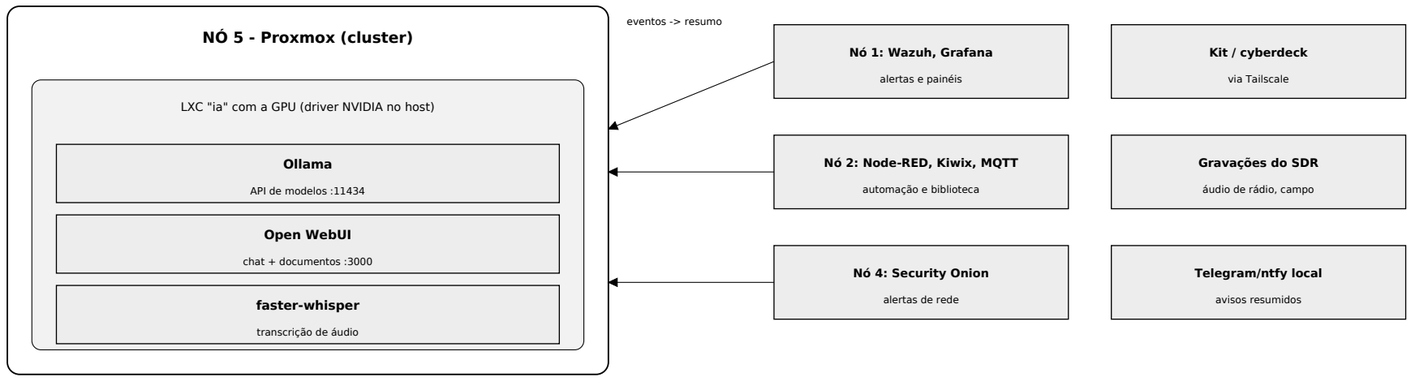
HOMELAB TINY - FASE 5: NÓ DE IA

Montagem: nó 5 no topo do rack e módulo GPU OCuLink

Autor: João Victor Paixão Zolim
github.com/joaovpzdev

Data	Escala	Folha
21/10/2026 - rev. A	1:3 / S/E	1/2
Unidade	**Projeção**	**Formato**
mm	1º diedro	A3

SERVIÇOS E INTEGRAÇÕES (VLAN 20, ACESSO SÓ PELO TAILSCALE)



CASOS DE USO

Uso	Fluxo	Modelo (12 GB)
Triagem de alertas	Wazuh/SO -> Node-RED -> Ollama -> resumo no Grafana	7-8B instruct
Assistente do lab	Open WebUI com os PDFs do repo, manuais, RFCs	7-14B + embeddings
Biblioteca offline	Perguntas sobre o Kiwix e documentos locais (RAG)	7-8B + embeddings
Transcrição	Áudio do SDR e de campo -> texto pesquisável	Whisper small/medium
Estudos	Writeups do Bandit, Packet Tracer, revisão de código	7-14B code
Relatório SAR	Log do Meshtastic -> rascunho do relatório	7-8B instruct

Tudo local: nenhum alerta, log ou posição sai de casa (LGPD).

LISTA DE MATERIAIS

It.	Descrição	R$ (estim.)
1	Lenovo M720q i5-8500T usado (nó 5)	~1.000
2	2 x 16 GB DDR4 SODIMM	~450
3	SSD SATA 2,5" 1 TB	~350
4	Adaptador M.2 NVMe -> OCuLink + cabo 50 cm	~150
5	Dock eGPU OCuLink	~450
6	Fonte SFX 600 W 80+ Gold	~600
7	RTX 3060 12 GB usada	~1.400
8	Perfil 2020, cantoneiras, pés e trava impressos	~180
9	Régua com DPS para o módulo	~80
	Total fase 5 (RTX 3060)	~4.660
10	RTX 3090 24 GB no lugar da 3060 (diferença; fonte 850 W) (opcional)	~3.800
11	Nobreak 1.200 VA (opcional)	~900

ENERGIA E CUSTO (ESTIMADOS)

Estado	RTX 3060	RTX 3090
Ocioso (nó + GPU + fonte)	~25-30 W	~35-40 W
Gerando texto	~200 W	~390 W
Por mês, 24/7 + 2 h/dia de uso	~R$ 30	~R$ 45

Tarifa considerada ~R$ 1,00/kWh (SP, com impostos).

O nobreak de 600-700 VA (~360 W) não aguenta a GPU:
módulo e nó 5 ficam na tomada com DPS. Opcional: nobreak
de 1.200 VA para colocar tudo protegido.

ESCOLHA DA PLACA (USADAS)

Placa	VRAM	Modelos (Q4)	TDP
RTX 3060 12 GB	12 GB	até ~14B	170 W
RTX 4060 Ti 16 GB	16 GB	até ~20B	165 W
RTX 3090 24 GB	24 GB	até ~32B	350 W
2 x MI50 (como no vídeo)	2 x 32 GB	70B+	2 x 300 W

NVIDIA: CUDA funciona direto no Ollama, sem gambiarra.

MI50: barata por GB, mas sem suporte oficial no ROCm
atual e precisa de fonte e ventilação de servidor.

ORDEM DE INSTALAÇÃO

1. Nó 5 no topo do rack; Proxmox e entrada no cluster.
2. BIOS: VT-d ligado; SSD SATA como boot.
3. Montar o módulo: quadro 2020, SFX, dock e GPU.
4. Adaptador no M.2, cabo pela abertura do slot PCIe.
5. Ligar GPU e depois o nó; conferir: lspci | grep NVIDIA.
6. Driver NVIDIA no host; GPU no LXC "ia".
7. Docker no LXC: Ollama, Open WebUI, faster-whisper.
8. Node-RED: fluxo de triagem dos alertas do Wazuh.
9. Teste de 1 h gerando texto: temperatura e consumo.

Preços estimados, out/2026; usados variam muito.

HOMELAB TINY - FASE 5: NÓ DE IA

Software, integrações, energia e materiais

Autor: João Victor Paixão Zolim
github.com/joaovpzdev

Data	Escala	Folha
21/10/2026 - rev. A	S/E	2/2
Unidade	Projeção	Formato
mm	1º diedro	A3